

Prepoznavanje i klasifikacija životne dobi i spola na temelju predane slike pomoću konvolucijskih neuronskih mreža

Matej Višnjić,

Fakultet informatike, Sveučilište Jurja Dobrile u Puli,


Ovim projektom razvijen je model za prepoznavanje životne dobi i prepoznavanje spola osobe na temelju predane slike. Skup podataka koji je korišten sadrži više od 20 000 slika ljudskih lica i imaju oznake starosti, spola i drugo. Arhitektura koja je korištena u modelu je konvolucijska neuronska mreža sa različitim konvolucijskim slojevima i cilj je bio da se dobije što bolja uspješnost modela. Uspješnost konačnog modela je približno jednako 89%, dok je gubitak godina oko 5.31.

1 Uvod

Neuronske mreže je vrsta strojnog učenja koja oponaša ponašanje bioloških neurona i veze između njih. Sadržavaju ulazni sloj, skriveni sloj (jedan ili više njih) i izlazni sloj. Neuronske mreže oslanjaju se na skupove podataka koje se koriste za treniranje istih neurona i cilj je dobiti što bolju točnost kako bi kasnije vrlo brzo klasificirali i grupirali podatke [1]. Postoji više vrsta neuronski mreža i svaka koristi drugačiji pristup. Isto tako, za bilo koju vrstu postoji namjena za što se točno može koristiti. Među popularnijim neuronskim mrežama: RNN (rekurentna neuronska mreža), Višeslojni perceptroni i CNN (konvolucijska neuronska mreža). U nastavku je općenito o CNN-u (konvolucijska neuronska mreža) koja je korištena u sklopu projekta.

CNN

Najviše korištena neuronska mreža u sklopu računalnog vida, klasifikacija slika i videa. Konvolucijska neuronska mreža sadržava više slojeva kao što su konvolucijski sloj, pooling, fully-connected [2]. Na slici 1. prikazan je grafički prikaz konvolucijske neuronske mreže.



Slika 1. Konvolucijska neuronska mreža [3]

Prema [3], Konvolucijska neuronska mreža sastoji se od 3 sloja:

1. Konvolucijski sloj (Conv)
2. Pooling sloj (Pool)
3. Fully connected Layer (Fc)

Više o tome biti će objašnjeno u poglavlju [3 Metodologija](#).

U današnje doba podaci kao što su slike su vrlo tražene neovisno o tome kakav se problem pokušava riješiti. Za trening neuronskih mreža potrebno je imati što više slika i labela koje ustvari predstavljaju podatke i rezultat, a model nam kasnije vraća natrag program. Na slici 2. prikazana je skica kako strojno učenje funkcionira.

STROJNO UČENJE (klasifikacija)



Slika 2. Strojno učenje

Najveći problem kod ovog projekta je pogoditi stvarne godine osobe koja je na slici. Također, poželjno je da predana slika bude izrezana do te granice da se samo lice vidi. Na slici 3. prikazan je primjer jedne od nekolicine testnih slika koje se koristi za prepoznavanje spola i godina.



Slika 3. Jedna od testnih slika

Kada se slika preprocesira, točnije kada slika raspodjeli na matrice piksela, slika se pretvara su sivu sliku. Više o tome biti će objašnjeno u poglavlju [4 Trening modela](#)

Motivacija za izradu projekta za predviđanje godina i spola ljudi ima potencijala za primjenu u marketingu prema ciljanim skupinama korisnika. Isto tako, može se poboljšavati sigurnost aplikacija i sustava putem biometrijske identifikacije ili medicinska istraživanja. Također, model se može primjeniti na daljna istraživanja i poboljšanja u sklopu umjetne inteligencije. Neke od nadogradnji modela koji se mogu primjeniti na ovaj rad, prepoznavanje i klasifikacija rase na temelju predane slike s obzirom da skup podataka sadrži labela godina, spola, rase i datum nastajanje slike.

Rad je organiziran na sljedeći način. U [poglavlju 2](#) opisani su postojeći modeli, zatim u [poglavlju 3](#) opisan je plan rješavanja problema. U [poglavlju 4](#) opisan je trening modela, a u [poglavlju 4.1](#) opisan konačan model. [Poglavlje 5](#) sadrži zaključak ovog rada.

2 Postojeći modeli

U ovome poglavlju biti će opisana dva postojeća modela za prepoznavanje i klasifikaciju spola i životne dobi.

U članku „Gender Recognition Through Face Using Deep Learning” [\[4\]](#) gdje je napravljen model za prepoznavanje spola pomoću slike lica od osobe. Skup podataka koji je korišten je VGGNet-face koji sadrži 10 000 slika osobnih iskaznica od poznatih ličnosti. Kao arhitekturu koristili su VGGNet ali su prilagodili neke od hiperparametara. Konačni model je prepravljen na način da su slike prvo skalirane na veličinu od 256 x 256 piksela, zatim obrezivanje na 227 x 227. Dodan je FC (Fully-connected layer) sloj koji prima izlaz iz trećeg konvolucijskog sloja, taj sloj sadrži 512 neurona i koristi funkciju „relu” a nakon toga slijedi „dropout” sa stopom 0.5. Drugi korak je vrlo sličan prvom gdje se dodaje dodatni FC sloj koji prima 512 dimenzionalni izlaz iz prvog FC. Zatim, treći FC sloj koji mapira izlaz u krajnje klase i klasificira spol. Izlaz iz trećeg sloja se prosljedi u softmax funkciju koja dodjeljuje vjerojatnost svakoj klasi spola. Veličina primjera podataka (batch) u svakoj iteraciji iznosi 64. U konačnici predikcija spola se temelji na labeli s najvećom vjerojatnosti na testnoj slici. Uspješnost ovog modela procjenjena je na 95%.

U članku „Age and Gender Classification using Convolutional Neural Networks” [\[5\]](#) gdje je koncipiran model za klasifikaciju životne dobi i spola koristeći CNN. Skup podataka koji su koristili nije implicitno naveden u članku. Međutim, autor je na Github-u [\[6\]](#) naveo koji podatak je korišten za navedeni projekt. Arhitekturu koju su koristili primjenjena je i za klasifikaciju dobi i za klasifikaciju spola. Sastoji se od tri konvolucijska sloja (CONV) i dva potpuno povezana (FC) s malim brojem neurona. Odabirom manje arhitekture smanjuje se rizik od overfitanja modela. Klasifikacija životne dobi potrebno je razlikovati između osam različitih

dobnih skupina a za spol dvije klase. Prvi konvolucijski sloj ima 96 filtera veličine 7x7. Drugi 256 filtera veličine 5x5. Treći konvolucijski sloj sadrži 384 filtera veličine 3x3 piksela. Zatim idu dva FC sloja. Svaki od njih sadrži 512 neurona. Izlazi se prosljeđuju „soft-max” sloju koji dodjeljuje vjerojatnost svakoj klasi. Veličina slika po iteraciji (batch) iznosi 50. Stopa učenja iznosi e^{-3} , a nakon 10 tisuća iteracija smanjuje se na e^{-4} . Osim što se koristi jednostavna arhitektura koriste se metode „dropout” koja iznosi 0.5 i augmentacija (data augmenation).

3 Metodologija

U ovome poglavlju objasniti će se koraci za rješavanje problema prepoznavanja i klasifikacije životne dobi i spola na temelju predane slike.

Glavni problem je razviti model koji sa visokom učinkovitosti može probati predvidjeti godine i spol osobe sa slike. Naravno, slika koja je predana na predviđanje mora biti obrezana tako da se vidi samo lice osobe. Slike sa pozadinom i slično neće uspjeti prepoznati kako treba.

Za model odabrana je konvolucijska neuronska mreža iz razloga što su najpopularnije za problem klasifikacije slika i vrlo su praktične za korištenje. Kao što je već spomenuto u poglavlju [1 Uvod](#), CNN je najviše korištena neuronska mreža u sklopu računalnog vida, klasifikacija slika i videa i sastoji se od CONV, POOL i FC sloja. Također, moguće je koristiti i neke druge metode kako bi se pospješio trening nad podacima. Koriste principe linearne algebre, poseban način množenja matrica kako bi uspješno prepoznali uzorke unutar slika [\[1\]](#). U nastavku ovog poglavlja objašnjeno je kako je odrađen dio za pripremu skupa podataka prije izrade samoga modela.

Skup podataka koji je korišten za treniranje i kasnije testiranje modela preuzet je sa [\[7\]](#) te sadrži više od 23 000 slika lica različitih osoba. Također, u skupu podataka postoje podaci (labele) o spolu (muško-žensko), godina (0-116 godina), rasa i datum kada je slika prikupljena u skup. Svaki naziv slike ima svoje podatke (npr. 20_0_0_20170117003449983). Međutim, za ovaj model korištene su samo labele za spol i godine.

Nakon što je preuzet skup podataka potrebno je proći kroz direktorij koji sadrži sve slike i odvojiti godine i spol osobe sa slike. Kada su labele uspješno odvojene kreirana je .csv datoteka koja sadrži putanju do slike, godine i spol.

Zatim je potrebno kreirati funkciju koja će svaku sliku procesuirati. Točnije, svakoj slici se mjenja veličina sa 200x200 piksela na 128 x 128 piksela. Isto tako, slikama se dodaje sivi tonovi i ukoliko je slika bila dubine 3, sada dubina postaje 1 (128,128,1).

Sada se može početi dijeliti podaci na trening i testni skup. Validacijski skup odvojen je direktno prije samog početka treninga. Postotak trening skupa koji je odvojen je 80% i 20% za testni skup. Validacijski skup je također 20% što znači da u konačnici imamo 60% trening skupa, 20% validacijskog i 20% testnog.

Kada je trening, validacija i testni skup uspješno odvojen onda se može pozvati funkcija za procesuiranje slika. I nakon toga slijedi normalizacija trening (i kasnije validacijskog) i normalizacija testnog skupa kako bi se smanjile varijacije između podataka. Nakon toga može se kreirati model, a o modelu biti će objašnjeno u poglavlju 4 Trening modela.

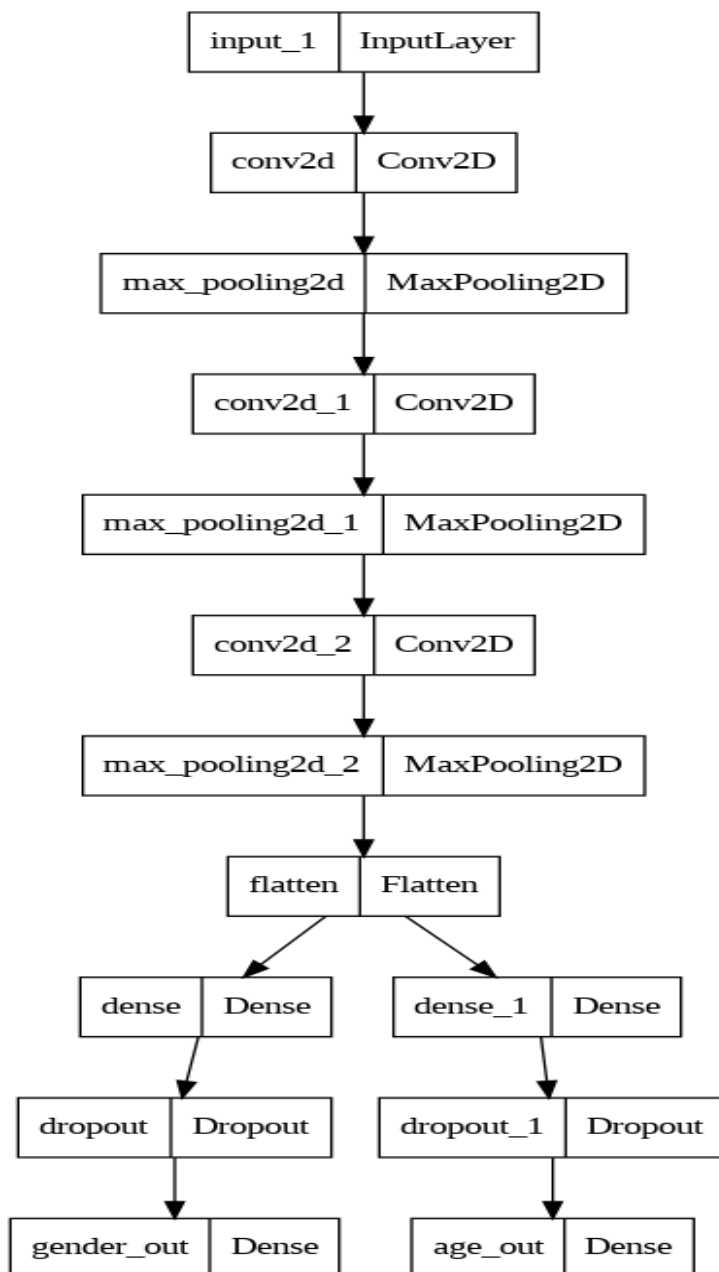
4 Trening modela

Prije trening modela kao što je već spomenuto u odlomku [3 Metodologija](#), potrebno je za skup podataka napraviti „preprocess” kako bi odgovarali ulaznom sloju za trening i bili pretvoreni u polje matrica kako bi model mogao uopće učitati sliku. „Preprocess” radi da uzme sliku i smanji je na 128 x 128 piksela, zatim pretvara sliku u crno bijelu kako bi smanjili kompleksnost podataka i ubrzao trening. Također, potrebno je napraviti i normalizaciju kako bi se pikseli sveli na 0 i 1. Nakon cijele pripreme podataka i slično može se početi sa izradom najoptimalnijeg modela.

Prva Iteracija (Uspješnost spol 89%, gubitak za godine 6.8)


Kao što je odlomku 2 Postojeći modeli, isprobana je jednostavna arhitektura sa 3 konvolucijska sloja i dva FC sloja, jedan za spol drugi za godine. Oba FC sloja sadrže 512 neurona. Nakon CONV i POOL sloja, korištena je metoda „dropout” kako bi se nasumično isključili neki od neurona. Prvo, ulazni sloj sastoji se od 128 x 128 x 1 (jer su slike pretvorene u sive tonove). Zatim slijede konvolucijski slojevi koji primjenjuju različite tehnike kako bi uhvatili različite značajke sa slike. Ukupno je 3 konvolucijska sloja gdje prvi ima 32 filtera, drugi 64 a treći 128. Nakon svakog konvolucijskog sloja slijedi grupiranje (MaxPooling) veličine 2x2 koji smanjuju dimenzije i rade mrežu još učinkovitijom. Nakon grupiranja ide ravnanje (flatten) koji izlaz iz zadnjeg sloja „ravna” kako bi se prešlo na potpuno povezan sloj (FC). Slojevi za isključivanje (Dropout) sa stopom 0.3 koji koriste regulaciju kako ne bi došlo do overfitiranja modela. Zatim izlazni sloj (Dense) koji ima dva izlazna sloja (gender_output i age_output). Gender_output ima jedan neuron a određen je funkcijom „sigmoid”, koja je prikladna za binarnu klasifikaciju (0,1 – muško,žensko). Age_output koristi se za predviđanje dobi također ima jedan neuron ali je određen funkcijom „relu”. U konačnici model se mora kompajlirati (model.compile) gdje se definira model sa ulaznim i izlaznim vrijednostima. Za kompajliranje modela korišten je optimizator „adam” i dvije funkcije gubitka „binary_crossentropy” i „mae” što je kratica od

„mean absolute error”. Kada je model spreman, kreće se na trening podataka (model.fit). Za trening odabran je 12 kao broj epoha i batch je 32. Znači da će 12 puta proći kroz cijeli trening podataka, a batch (veličina serije) broj primjera koji se koriste u svakoj iteraciji. Na slici 4. prikazan je grafički prikaz modela.





Slika 4. Model iteracija 1

Nakon treninga, dolazimo do rezultata gdje je uspješnost za predviđanje spola na visokih 96%, dok za predviđanje godina gubitak iznosi 6.81. S obzirom za predviđanje godina metrika točnosti nije prikladna za praćenje, već se gleda gubitak. Što je manji gubitak veća je šansa da predvidi godine osobe. Na slici 5 prikazani su grafovi za uspješnost i gubitak za spol, a na slici 6 gubitak za godine.



Slika 5. Uspješnost i gubitak za spol



Slika 6. Gubitak za godine

Testne slike koje su testirane putem evaulacije modela (`model.evaulate`), gdje je dobivena uspješnost od 89% za spol a gubitak za godine iznosi 6.8. Isprobana je još jedna testna slika koja je navedena u odlomku 1 Uvod. Model je dobro predvidio da li je na slici muško ili žensko, međutim godine koje je predvidio daleko odstupaju od stvarnih godina osobe sa slike. Stvarne godine osobe sa slike jesu 24, dok je model predvidio da osoba ima 53 godine. Na slici 7. možete vidjeti predviđanje za testnu sliku.

1/1 [=====] - 0s 21ms/step
Predicted Gender: Male Predicted Age: 53

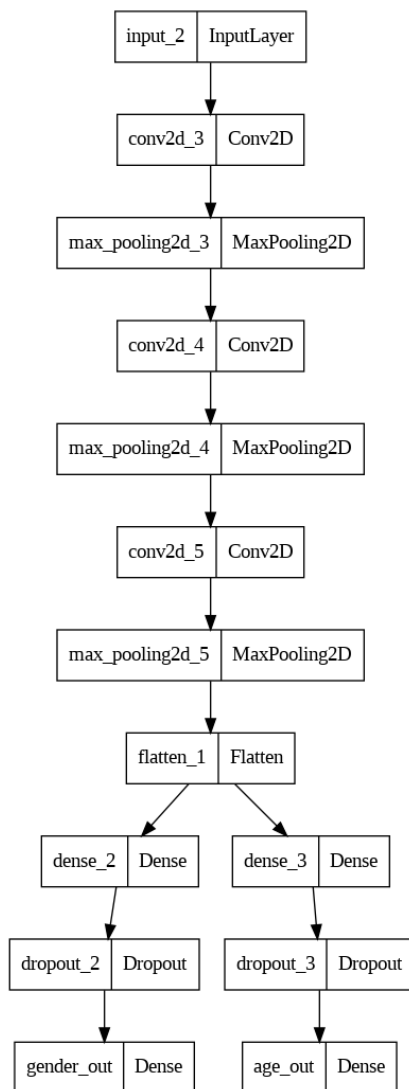


*Slika 7. Testna slika za predviđanje
spola i godina*

Druga iteracija (Uspješnost spol 88%, gubitak za godine 7.8)



U drugoj iteraciji koristila se također jednostavna arhitektura od tri konvolucijska sloja i dva FC sloja za godine i spol koji sadrže 256 neurona. Ukupno je 3 konvolucijska sloja gdje prvi ima 32 filtera, drugi 64 a treći 128. Nakon svakog konvolucijskog sloja slijedi grupiranje (MaxPooling) veličine 2x2 koji smanjuju dimenzije i rade mrežu još učinkovitijom. Nakon grupiranja ide ravnanje (flatten) koji izlaz iz zadnjeg sloja „ravna” kako bi se prešlo na potpuno povezan sloj (FC). Slojevi za isključivanje (Dropout) sa stopom 0.5 koji koriste regulaciju kako ne bi došlo do overfitanja modela. Zatim izlazni sloj (Dense) koji ima dva izlazna sloja (gender_output i age_output). Gender_output ima jedan neuron a određen je funkcijom „sigmoid”, koja je prikladna za binarnu klasifikaciju (0,1 – muško,žensko). Age_output koristi se za predviđanje dobi također ima jedan neuron ali je određen funkcijom „relu”. Za

kompajliranje modela korišten je optimizator „adam” i dvije funkcije gubitka „binary_crossentropy” i „mae” što je kratica od „mean absolute error”. Kada je model spreman, kreće se na trening podataka (model.fit). Za trening odabran je 12 kao broj epoha i batch je 128. Znači da će 12 puta proći kroz cijeli trening podataka, a batch (veličina serije) broj primjera koji se koriste u svakoj iteraciji. Na slici 8. prikazan je grafički prikaz modela.




Slika 8. Grafički prikaz modela

Nakon treninga, dolazimo do rezultata gdje je uspješnost za predviđanje spola na 88%, dok za predviđanje godina gubitak iznosi 7.8. Na slici 9 prikazani su grafovi za uspješnost i gubitak za spol, a na slici 10 gubitak za godine.



Slika 9. Uspješnost i gubitak za spol



Slika 10. Gubitak za godine

Testne slike koje su testirane putem evaulacije modela (`model.evaulate`), gdje je dobivena uspješnost od 87% za spol a gubitak za godine iznosi 7.82. Isprobana je opet ista slika kao u prijašnjoj iteraciji. Model je dobro predvidio da li je na slici muško ili žensko, međutim godine koje je predvidio daleko odstupaju od stvarnih godina osobe sa slike. Model je predvidio 50 godina za osobu na slici. Na slici 11. prikazano je predviđanje za testnu sliku.

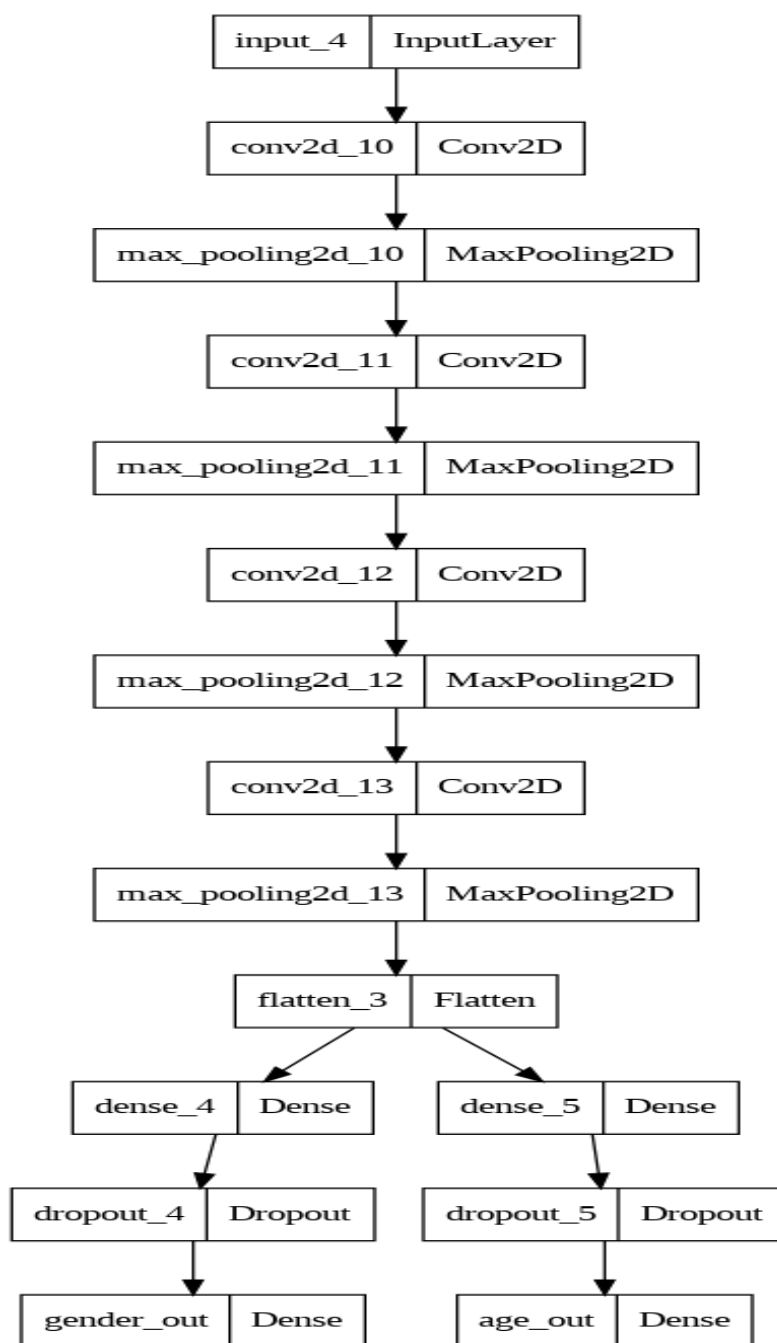
1/1 [=====] - 0s 31ms/step
Predicted Gender: Male Predicted Age: 50



*Slika 11. Testna slika za predviđanje
godina i spola*

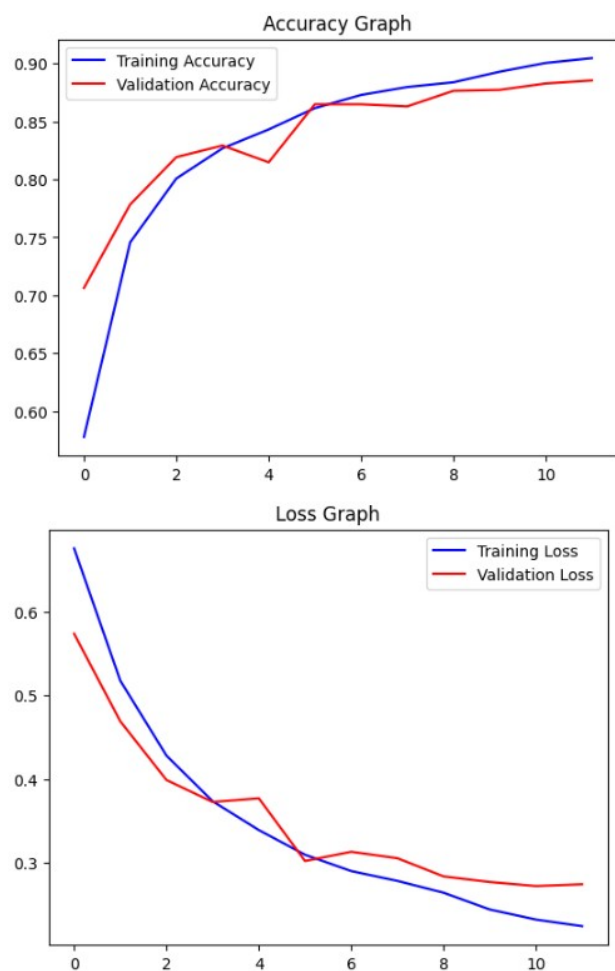
Treća iteracija (Uspješnost spol 88%, gubitak za godine 6.8)

U trećoj iteraciji dodan je još jedan konvolucijski sloj i dva FC sloja za godine i spol koji sadrže 512 neurona. Ukupno je 4 konvolucijska sloja gdje prvi ima 32 filtera, drugi 64 a treći 128 a četvrti 256. Nakon svakog konvolucijskog sloja slijedi grupiranje (MaxPooling) veličine 2x2 koji smanjuju dimenzije i rade mrežu još učinkovitijom. Nakon grupiranja ide ravnanje (flatten) koji izlaz iz zadnjeg sloja „ravna” kako bi se prešlo na potpuno povezan sloj (FC). Slojevi za isključivanje (Dropout) sa stopom 0.3 koji koriste regulaciju kako ne bi došlo do overfitiranja modela. Zatim izlazni sloj (Dense) koji ima dva izlazna sloja (gender_output i age_output). Gender_output ima jedan neuron a određen je funkcijom „sigmoid”, koja je prikladna za binarnu klasifikaciju (0,1 – muško,žensko). Age_output koristi se za predviđanje dobi također ima jedan neuron ali je određen funkcijom „relu”. Za kompajliranje modela korišten je optimizator „adam” i dvije funkcije gubitka „binary_crossentropy” i „mae” što je kratica od „mean absolute error”. Kada je model spreman, kreće se na trening podataka (model.fit). Za trening odabran je 12 kao broj epoha i batch je 64. Znači da će 12 puta proći kroz cijeli trening podataka, a batch (veličina serije) broj primjera koji se koriste u svakoj iteraciji. Na slici 12. prikazan je grafički prikaz modela.




Slika 12. Grafički prikaz modela

Nakon treninga, dolazimo do rezultata gdje je uspješnost za predviđanje spola na 88%, dok za predviđanje godina gubitak iznosi 6.8. Na slici 13 prikazani su grafovi za uspješnost i gubitak za spol, a na slici 14 gubitak za godine.



Slika 13. Uspješnost i gubitak za spol



Slika 14. Gubitak za godine

Testne slike koje su testirane putem evaulacije modela (`model.evaulate`), gdje je dobivena uspješnost od 88% za spol a gubitak za godine iznosi 6.88. Isprobana je opet ista slika kao u prijašnjoj iteraciji. Model je dobro predvidio da li je na slici muško ili žensko, međutim godine koje je predvidio daleko odstupaju od stvarnih godina osobe sa slike. Model je predvidio 62 godina za osobu na slici. Na slici 15. prikazano je predviđanje za testnu sliku.

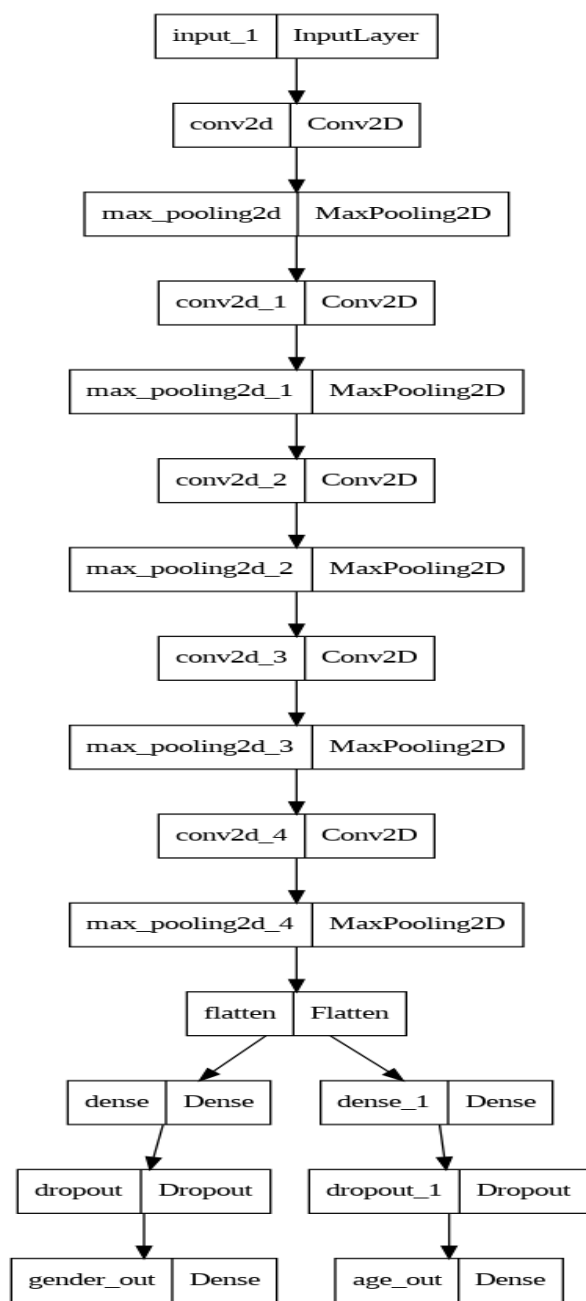
1/1 [=====] - 0s 21ms/step
Predicted Gender: Male Predicted Age: 62



Slika 15. Testna slika za predviđanje godina i spola



4.1 Konačni model (Uspješnost spol 89%, gubitak godine 5.31)

U konačnoj iteraciji dodan je još jedan konvolucijski sloj i dva FC sloja za godine i spol koji sadrže 512 neurona. Ukupno je 5 konvolucijska sloja gdje prvi ima 32 filtera, drugi 64 a treći 128, četvrti 256 a peti 512. Nakon svakog konvolucijskog sloja slijedi grupiranje (MaxPooling) veličine 2x2 koji smanjuju dimenzije i rade mrežu još učinkovitijom. Nakon grupiranja ide ravnjanje (flatten) koji izlaz iz zadnjeg sloja „ravna” kako bi se prešlo na potpuno povezan sloj (FC). Slojevi za isključivanje (Dropout) sa stopom 0.3 koji koriste regulaciju kako ne bi došlo do overfitiranja modela. Zatim izlazni sloj (Dense) koji ima dva izlazna sloja (gender_output i age_output). Gender_output ima jedan neuron a određen je funkcijom „sigmoid”, koja je prikladna za binarnu klasifikaciju (0,1 – muško,žensko). Age_output koristi se za predviđanje dobi također ima jedan neuron ali je određen funkcijom „relu”. Za kompajliranje modela korišten je optimizator „adam” i dvije funkcije gubitka „binary_crossentropy” i „mae” što je kratica od „mean absolute error”. Kada je model spreman, kreće se na trening podataka (model.fit). Za trening odabran je 12 kao broj epoha i batch je 32. Znači da će 12 puta proći kroz cijeli trening podataka, a batch (veličina serije) broj primjera koji se koriste u svakoj iteraciji. Na slici 16. prikazan je grafički prikaz modela.




Slika 16. Grafički prikaz konačnog modela

Nakon treninga, dolazimo do rezultata gdje je uspješnost za predviđanje spola na 87%, dok za predviđanje godina gubitak iznosi 6.7. Na slici 17 prikazani su grafovi za uspješnost i gubitak za spol, a na slici 18 gubitak za godine.



Slika 17. Uspješnost i gubitak za spol



Slika 18. Gubitak za godine

Testne slike koje su testirane putem evaulacije modela (model.evaulate), gdje je dobivena uspješnost od 87% za spol a gubitak za godine iznosi 6.8. Isprobana je opet ista slika kao u prijašnjoj iteraciji. Model je dobro predvidio da li je na slici muško ili žensko, međutim godine koje je predvidio manje odstupaju od stvarnih godina osobe na slici. Model je predvidio 25 godina za osobu na slici. Na slici 19. prikazano je predviđanje za testnu sliku. Također, na slikama 20 i 21 nalaze se predviđanje slika iz testnog skupa.

1/1 [=====] - 0s 83ms/step
Predicted Gender: Male Predicted Age: 25



*Slika 19. Testna slika za predviđanje
godina i spola*

Original Gender: Female Original Age: 8
1/1 [=====] - 0s 122ms/step
Predicted Gender: Female Predicted Age: 3



*Slika 20. Testna slika iz testnog
skupa*

Original Gender: Male Original Age: 20
1/1 [=====] - 0s 21ms/step
Predicted Gender: Male Predicted Age: 24



*Slika 21. Testna slika iz testnog
skupa*

5 Zaključak

S obzirom na to da je predviđanje godina i spola vrlo složeni problem i nije lako točno predvidjeti spol, a kamoli godine na temelju predane slike. U ovom projektu otkriveni su neki problemi. Internetskom pretragom srodnih modela otkriveno je da gotovo nitko nije radio model za predviđanje godina i spola u jednom. Svi modeli koji su se radili bili su posebno za treniranje godine i posebno za treniranje spola. Zato ovim modelom vrlo teško se mogu predvidjeti točne godine i spol osobe na temelju predane slike. U skupu podataka, godine su u rasponu od 0-116 i vrlo je teško savršeno istrenirati model da može točno odrediti koliko osoba ima godina. Isto tako, korištena je besplatna inačica „Google Colab-a” i nakon nekog vremena korištenja, „Google” je odlučio ugasiti pristup GPU načinu treniranja i bilo je vrlo teško postići što bolji trening podataka. Treniranje modela u ovom slučaju bio bi relevantniji kada bi se odvojilo na dva modela i kada bi model predviđao godine po grupama godinama (npr. 0-10, 11-20...). To bi automatski rezultiralo veću točnost za predviđanje spola i manji gubitak na godinama. Konačni spremljeni model može se pronaći na [\[8\]](#). Također, rad je objavljen na Githubu [\[9\]](#).

Literatura

- [1] What are neural networks? (n.d.). Retrieved from <https://www.ibm.com/topics/neural-networks>
- [2] Boesch, G. (2022). Retrieved from <https://viso.ai/deep-learning/deep-neural-network-three-popular-types/>
- [3] Arc. (2018). Retrieved from <https://towardsdatascience.com/convolutional-neural-network-17fb77e76c05>
- [4] Dhomne, A., Kumar, R., & Bhan, V. (2018). Gender recognition through face using Deep Learning. *Procedia Computer Science*, 132, 2–10. doi:10.1016/j.procs.2018.05.053
- [5] Levi, G., & Hassner, T. (2015). Age and gender classification using Convolutional Neural Networks. *2015 IEEE Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*. doi:10.1109/cvprw.2015.7301352
- [6] https://talhassner.github.io/home/publication/2015_CVPR
- [7] <https://susanqq.github.io/UTKFace/>
- [8] https://drive.google.com/file/d/18NqIoq6PVti_PZxcUXTsj4S3YUWupXZj/view?usp=sharing
- [9] <https://github.com/mvisnjic/age-and-gender-prediction-using-CNN>